데이터분석 또는 머신러닝을 위한 기초통계

농부는 매년 수확량이 달라지는 것을 보고 궁금증을 느꼈습니다.

매년 달라지는 수확량을 그래프로 분석하자.

- 수확량은 300kg에서 700kg 사이에서 분포하고 있다.

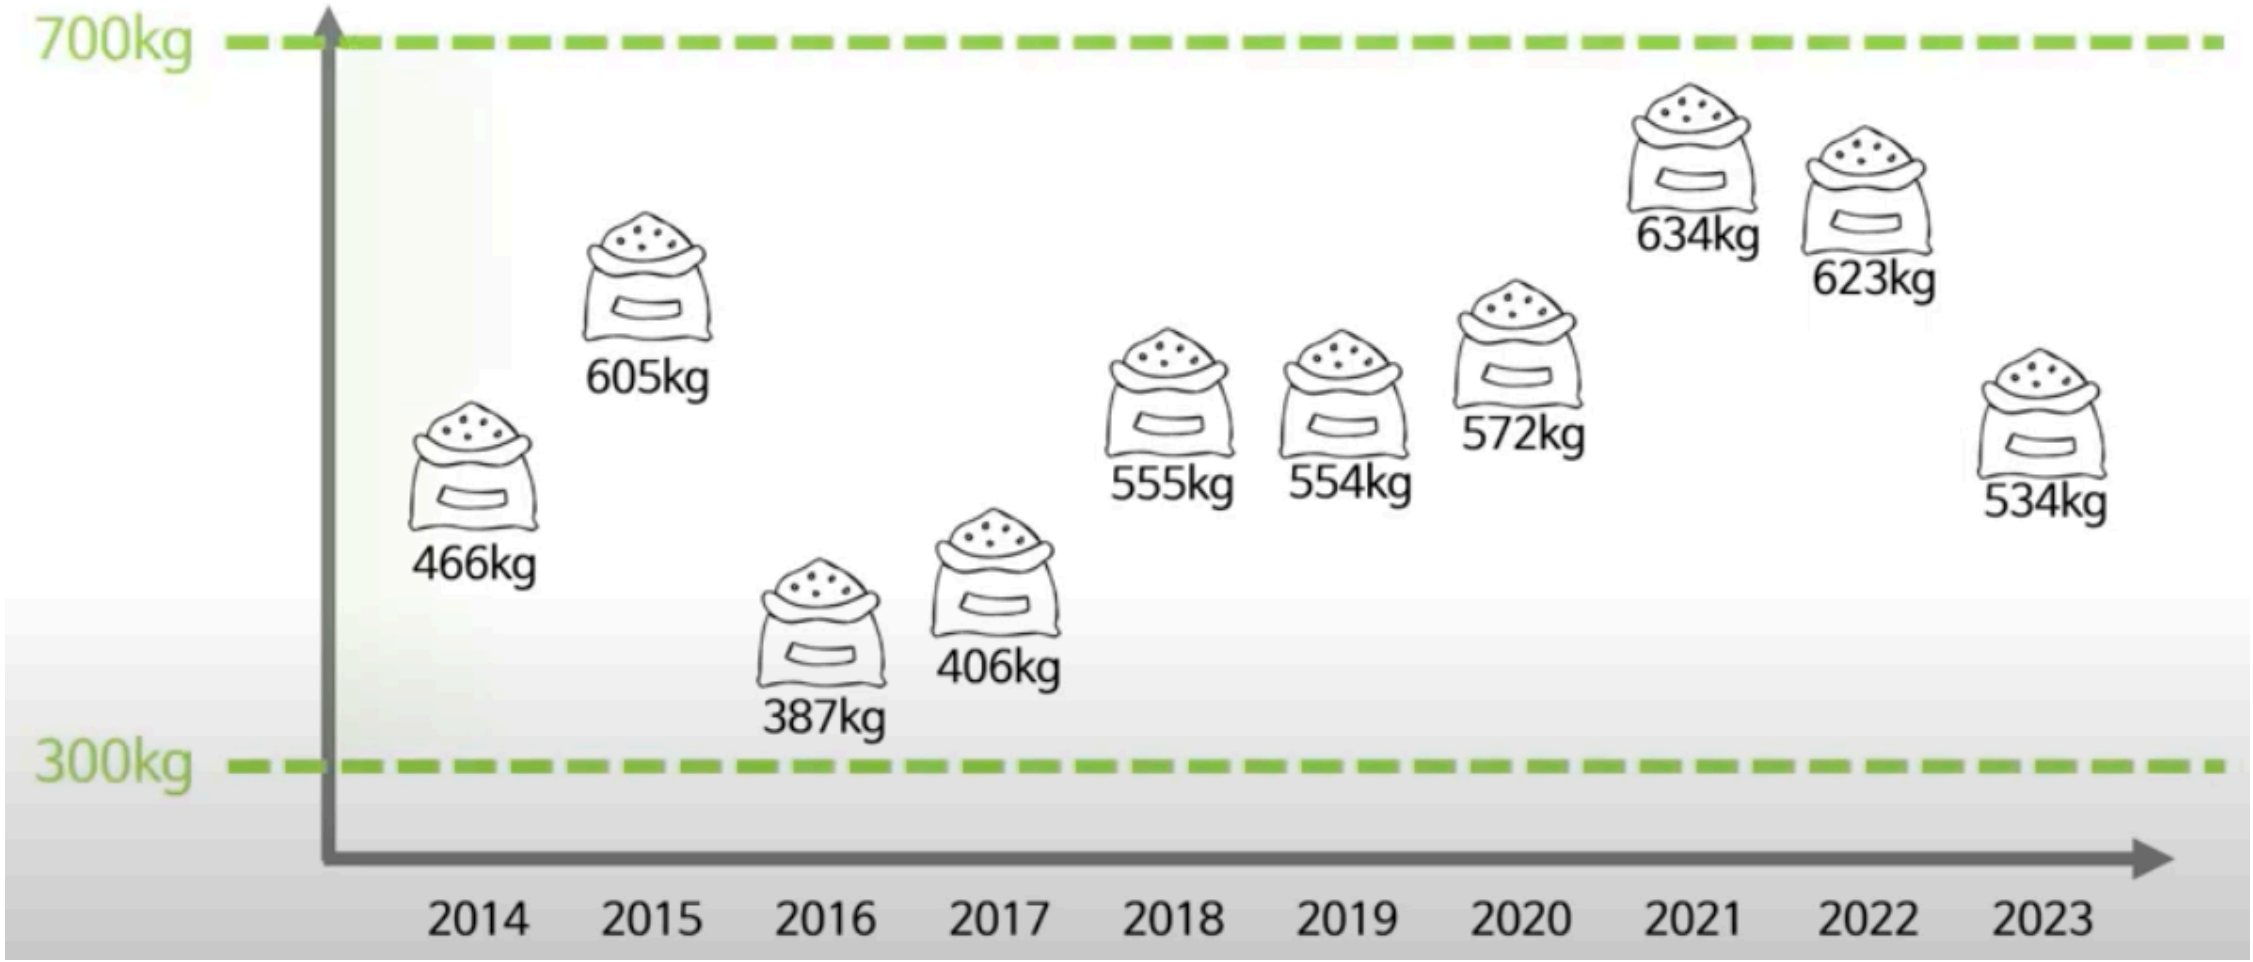

수확량의 평균을 구해보자.

$$\frac{466kg + 605kg + 387kg + 406kg + 555kg + 554kg + 572kg + 634kg + 623kg + 534kg}{10} = 533.6kg$$

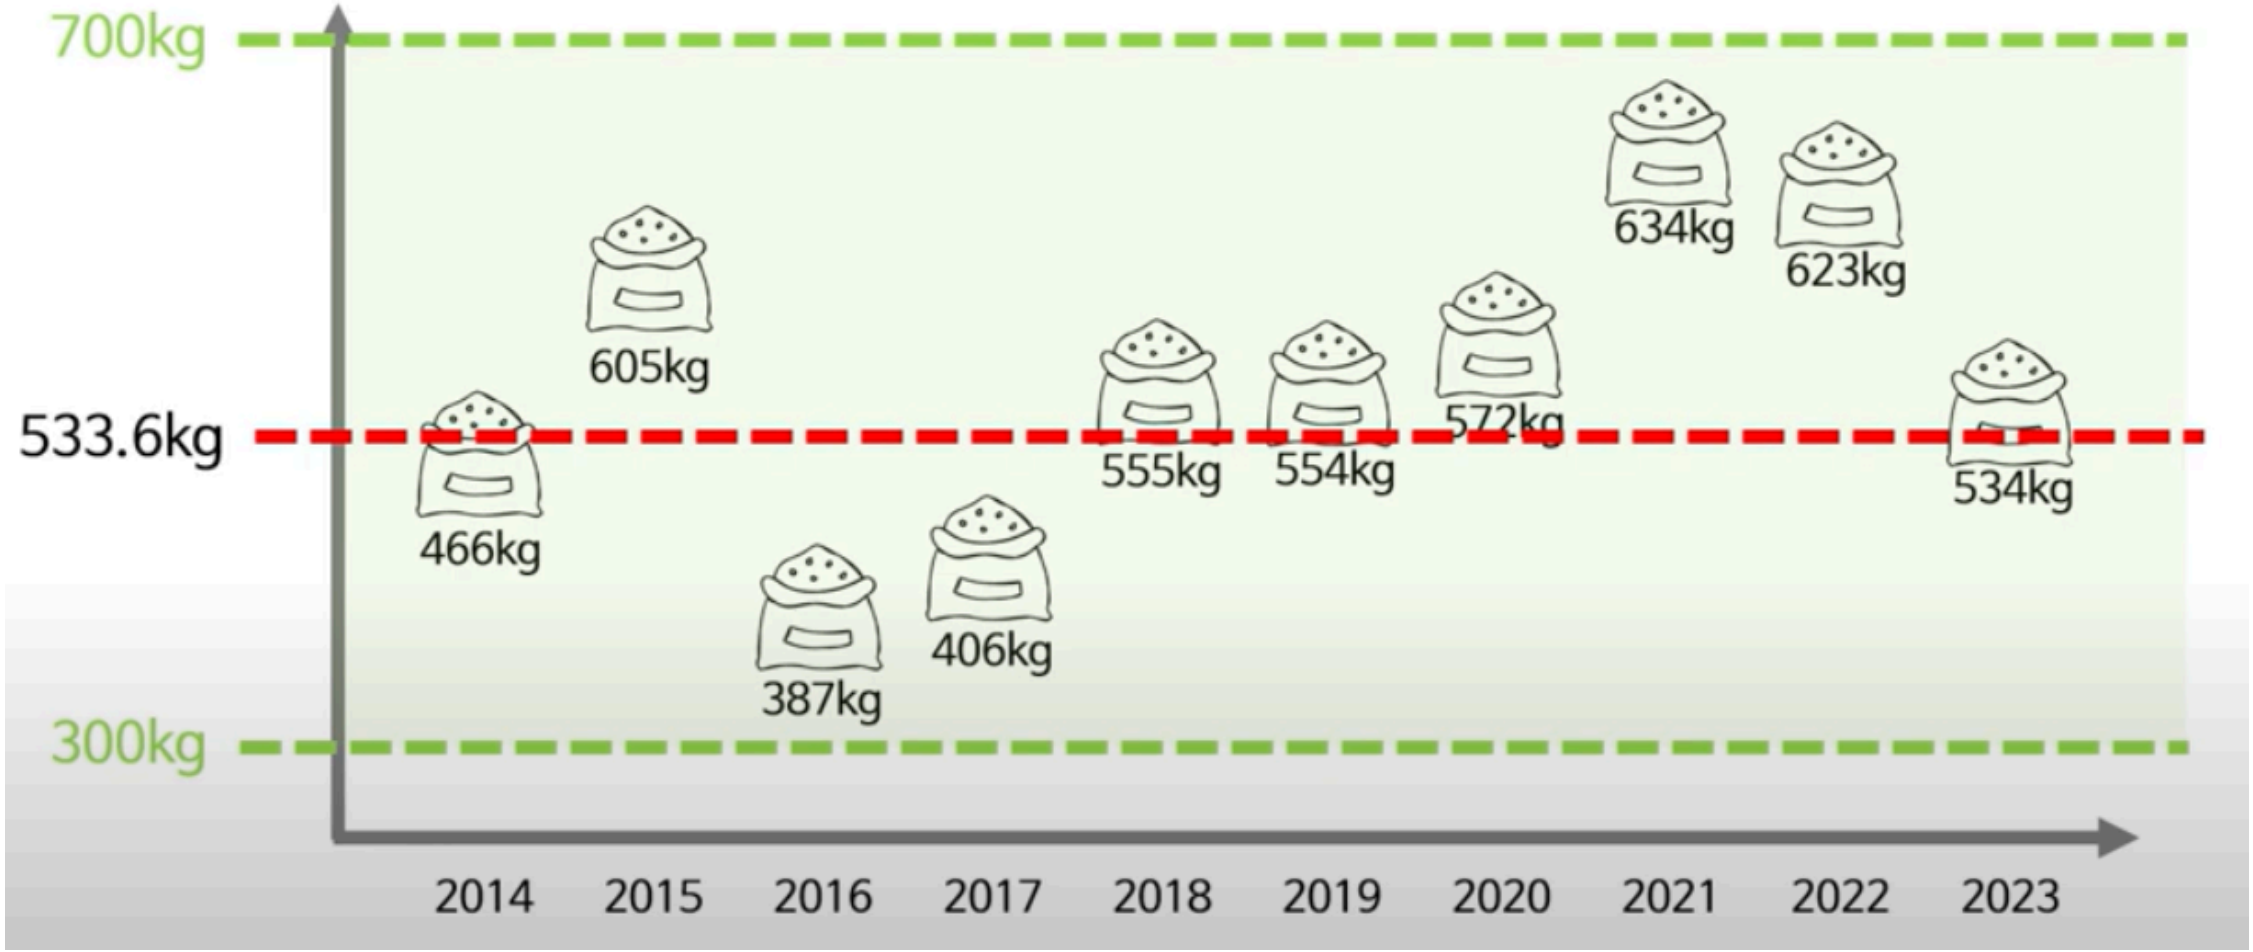

매년 수확량이 평균에서 얼마나 떨어져 있는지 확인해보자.

$$표준편차 : s_x = \sqrt{\frac{1}{n}\sum(x_i - \bar{x})^2} = 82.37$$

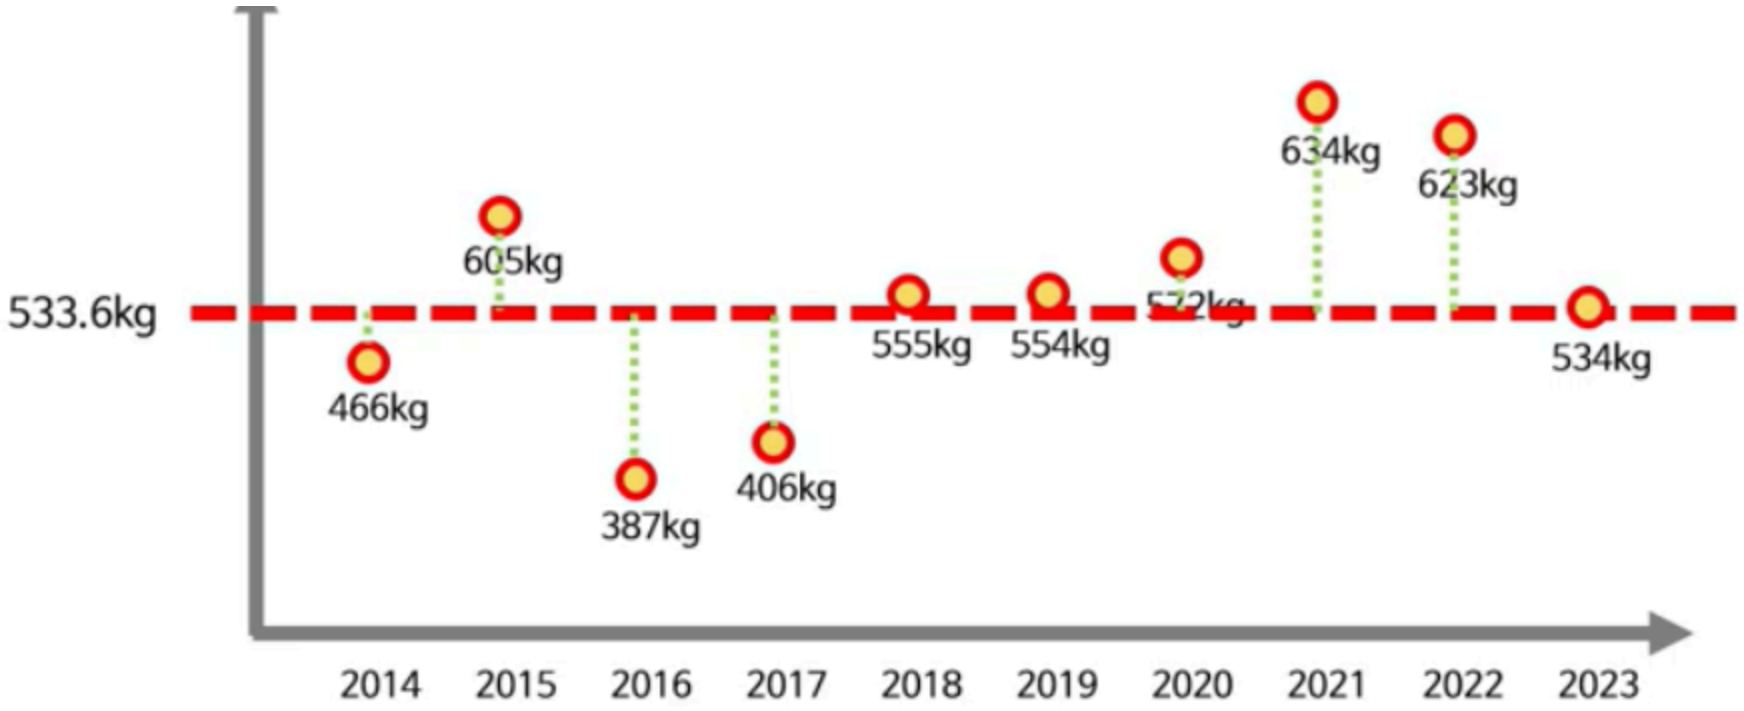

표준편차를 통해 지역별 수확량의 변동성을 예측할 수 있다.

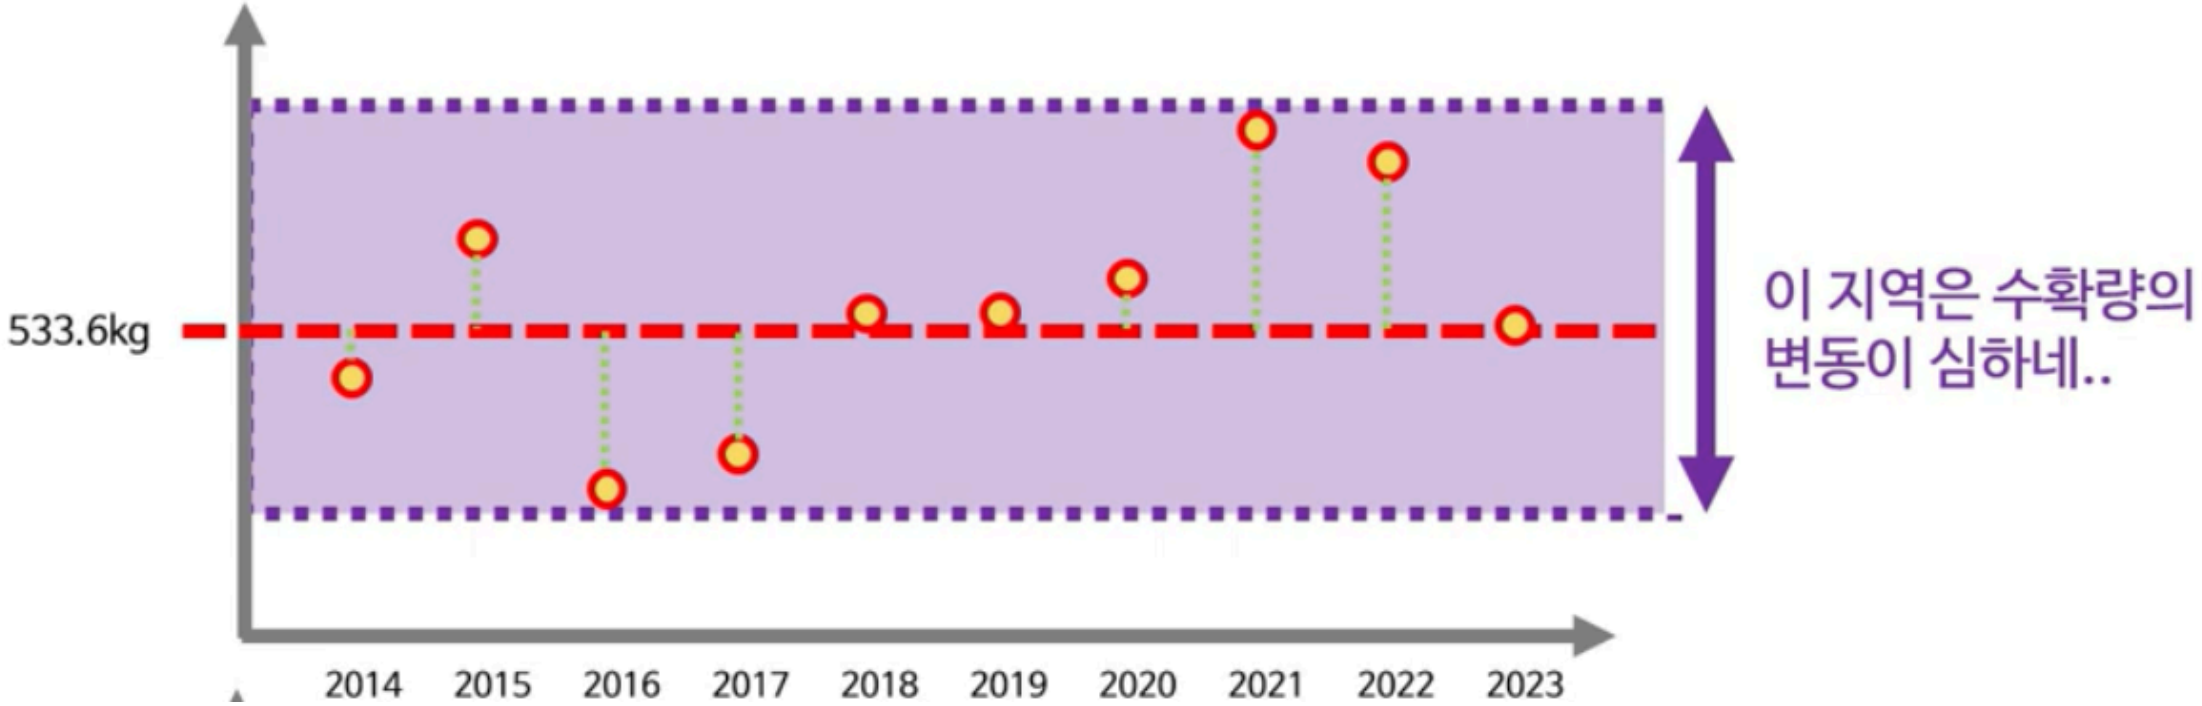

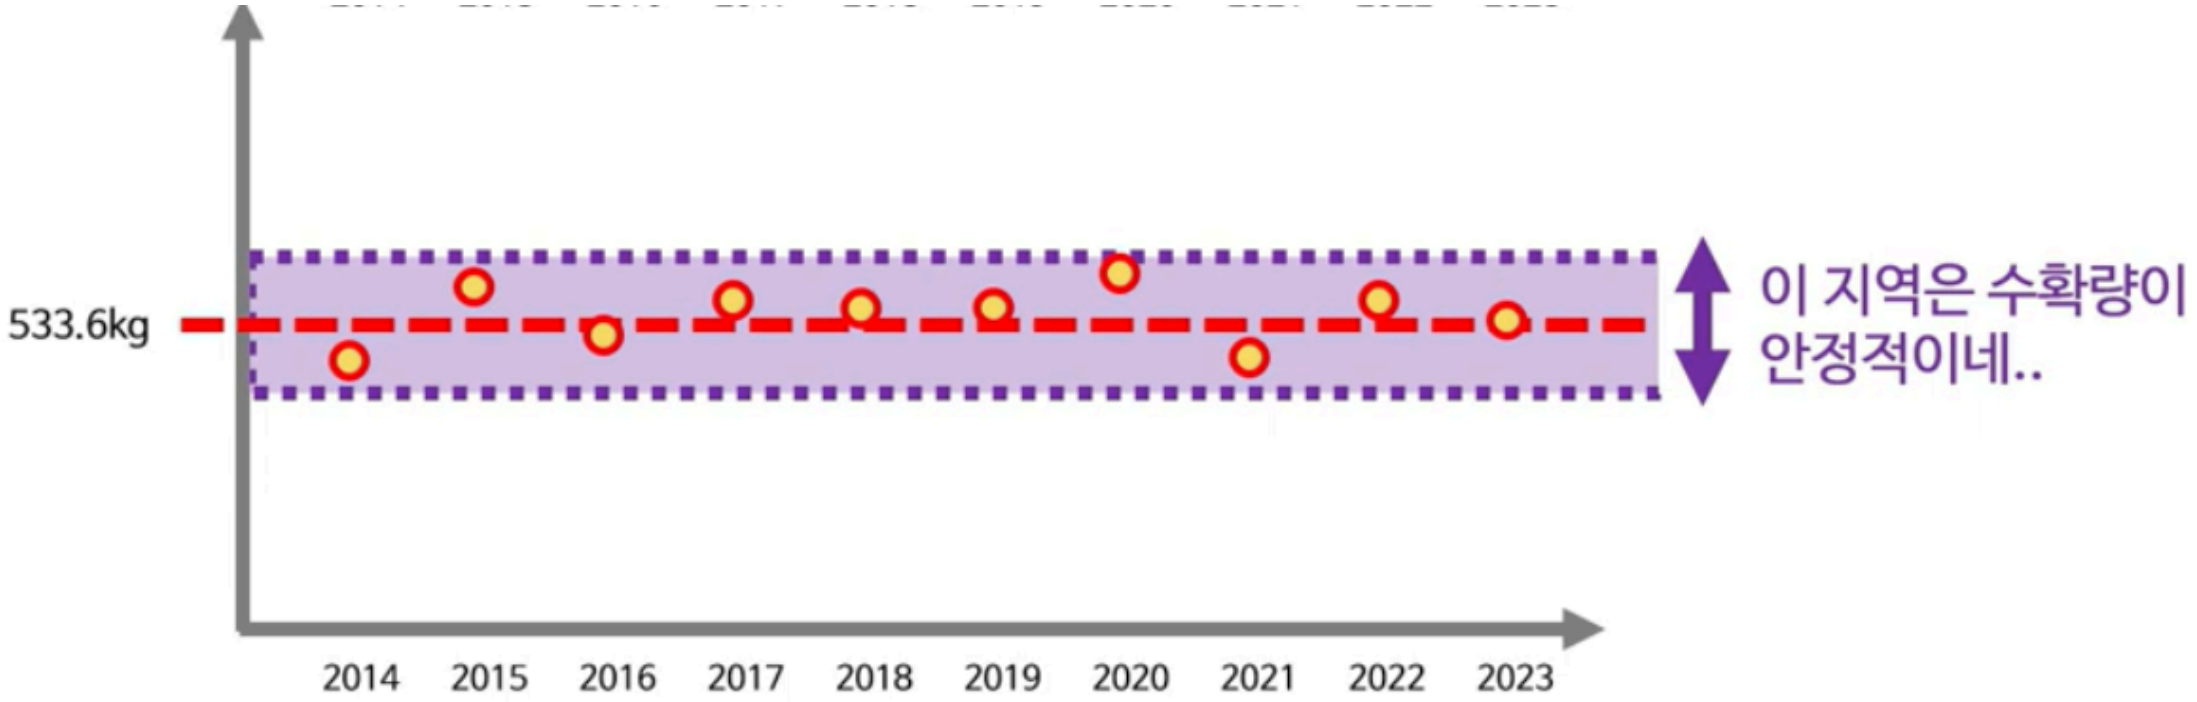
533.6kg
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
이 지역은 수확량이
안정적이네..

평균에서 멀어질수록 그 빈도수가 줄어드는 경향을 발견할 수 있다.

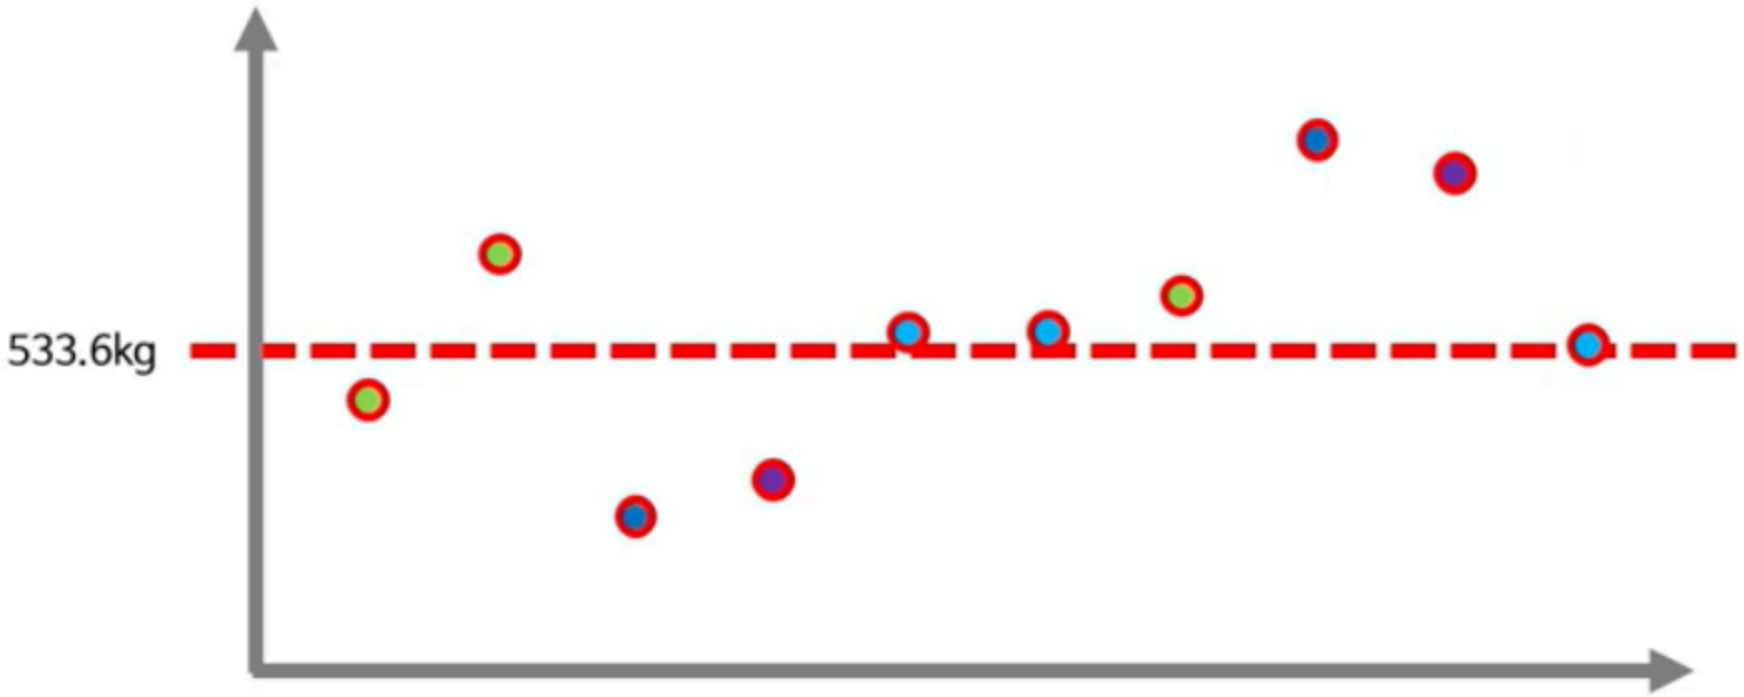

정규분포에서는 평균을 중심으로 대칭적으로 값들이 분포하며, 평균에서 멀어질수록 빈도가 줄어듭니다.

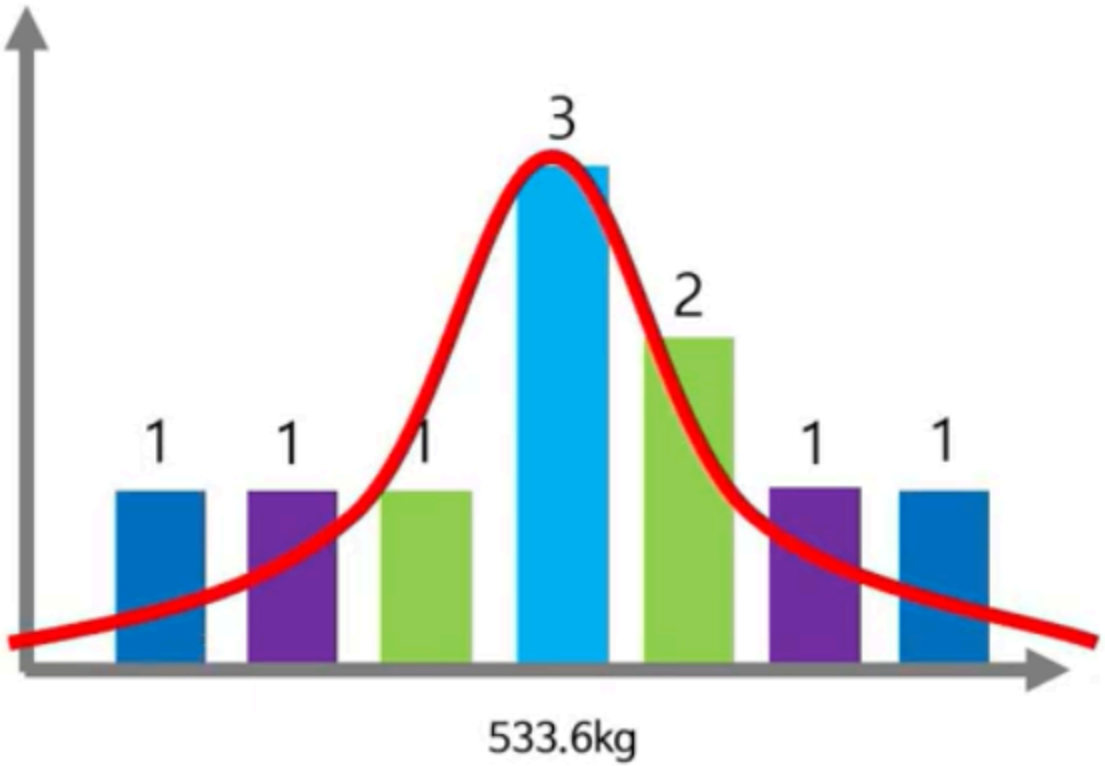

수확량에 영향을 주는 변수 정의

- 마을의 인구수, 농부가 소유한 논의 넓이, 올해 내린 비의 양 등

독립변수 & 종속변수

- 독립변수란, 종속변수에 영향을 주는 변수이다.
- 종속변수란, 독립변수를 조절할 때 그에 따라서 변화되는 변수이다.

독립변수: 강우량 비료의 양 씨앗 등급

종속변수: 수확량

예를 들어, 농부가 비료의 양(독립변수)을 조절하면 수확량(종속변수)이 변하는 것입니다.

비료를 많이 주면..

수확량이 많고..

비료를 작게 주면..

수확량이 작지 않을까?

상관관계

- 비료의 양과 수확량 간의 상관관계를 분석해보니, 비료를 많이 줄수록 수확량이 증가하는 경향이 있었습니다.

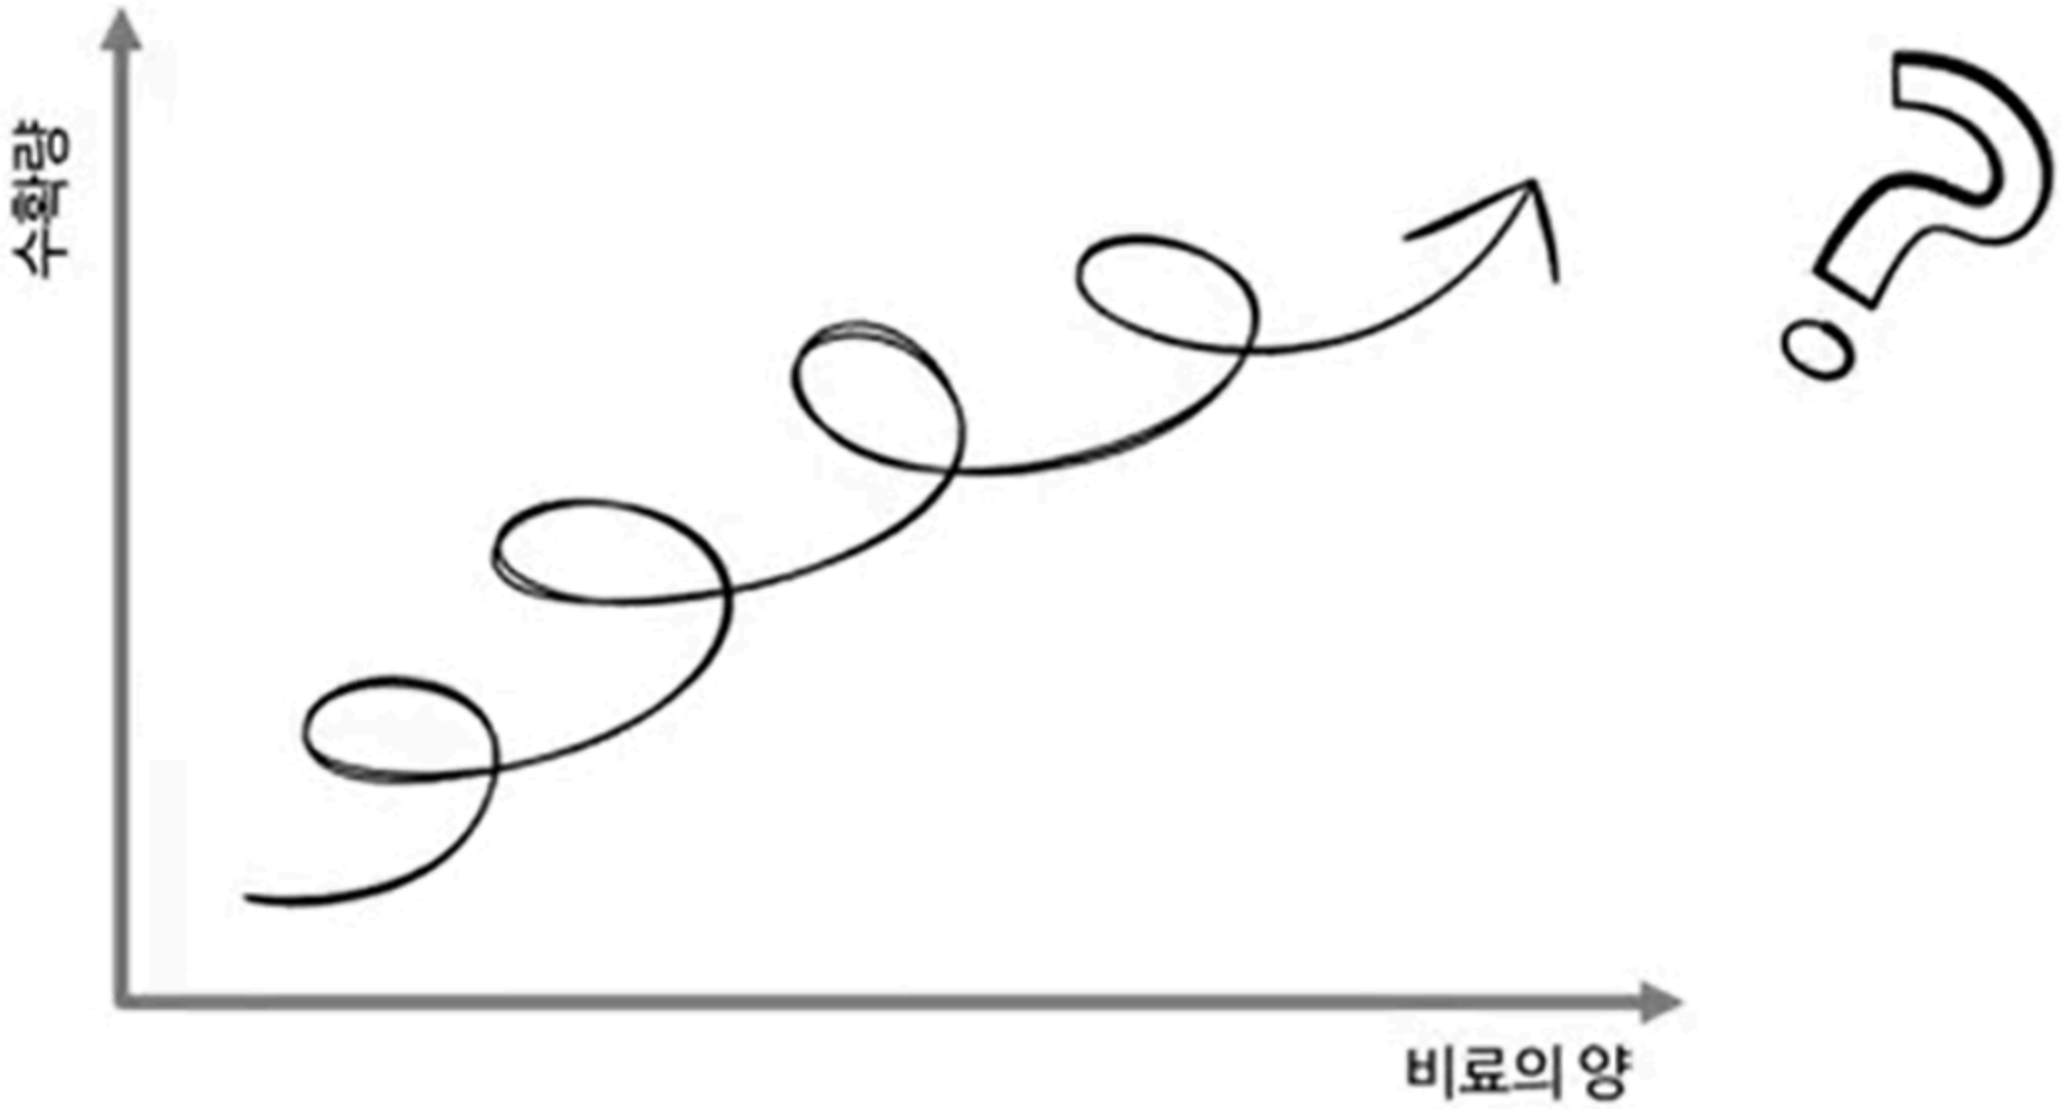
수확량
비료의 양

상관관계가 곧 인과관계는 아니다!

- 예를 들어, 달-토성간 거리와 물리학 학사 졸업생수 사이에도 강력한 상관관계가 있습니다.
- 이때 만약 지구상에 더 많은 물리학 학사 졸업생들이 증가한다고 하더라도 달-토성간 거리가 변하지는 않는다.

즉, 상관관계는 있지만 인과관계는 아니라는 뜻이다.

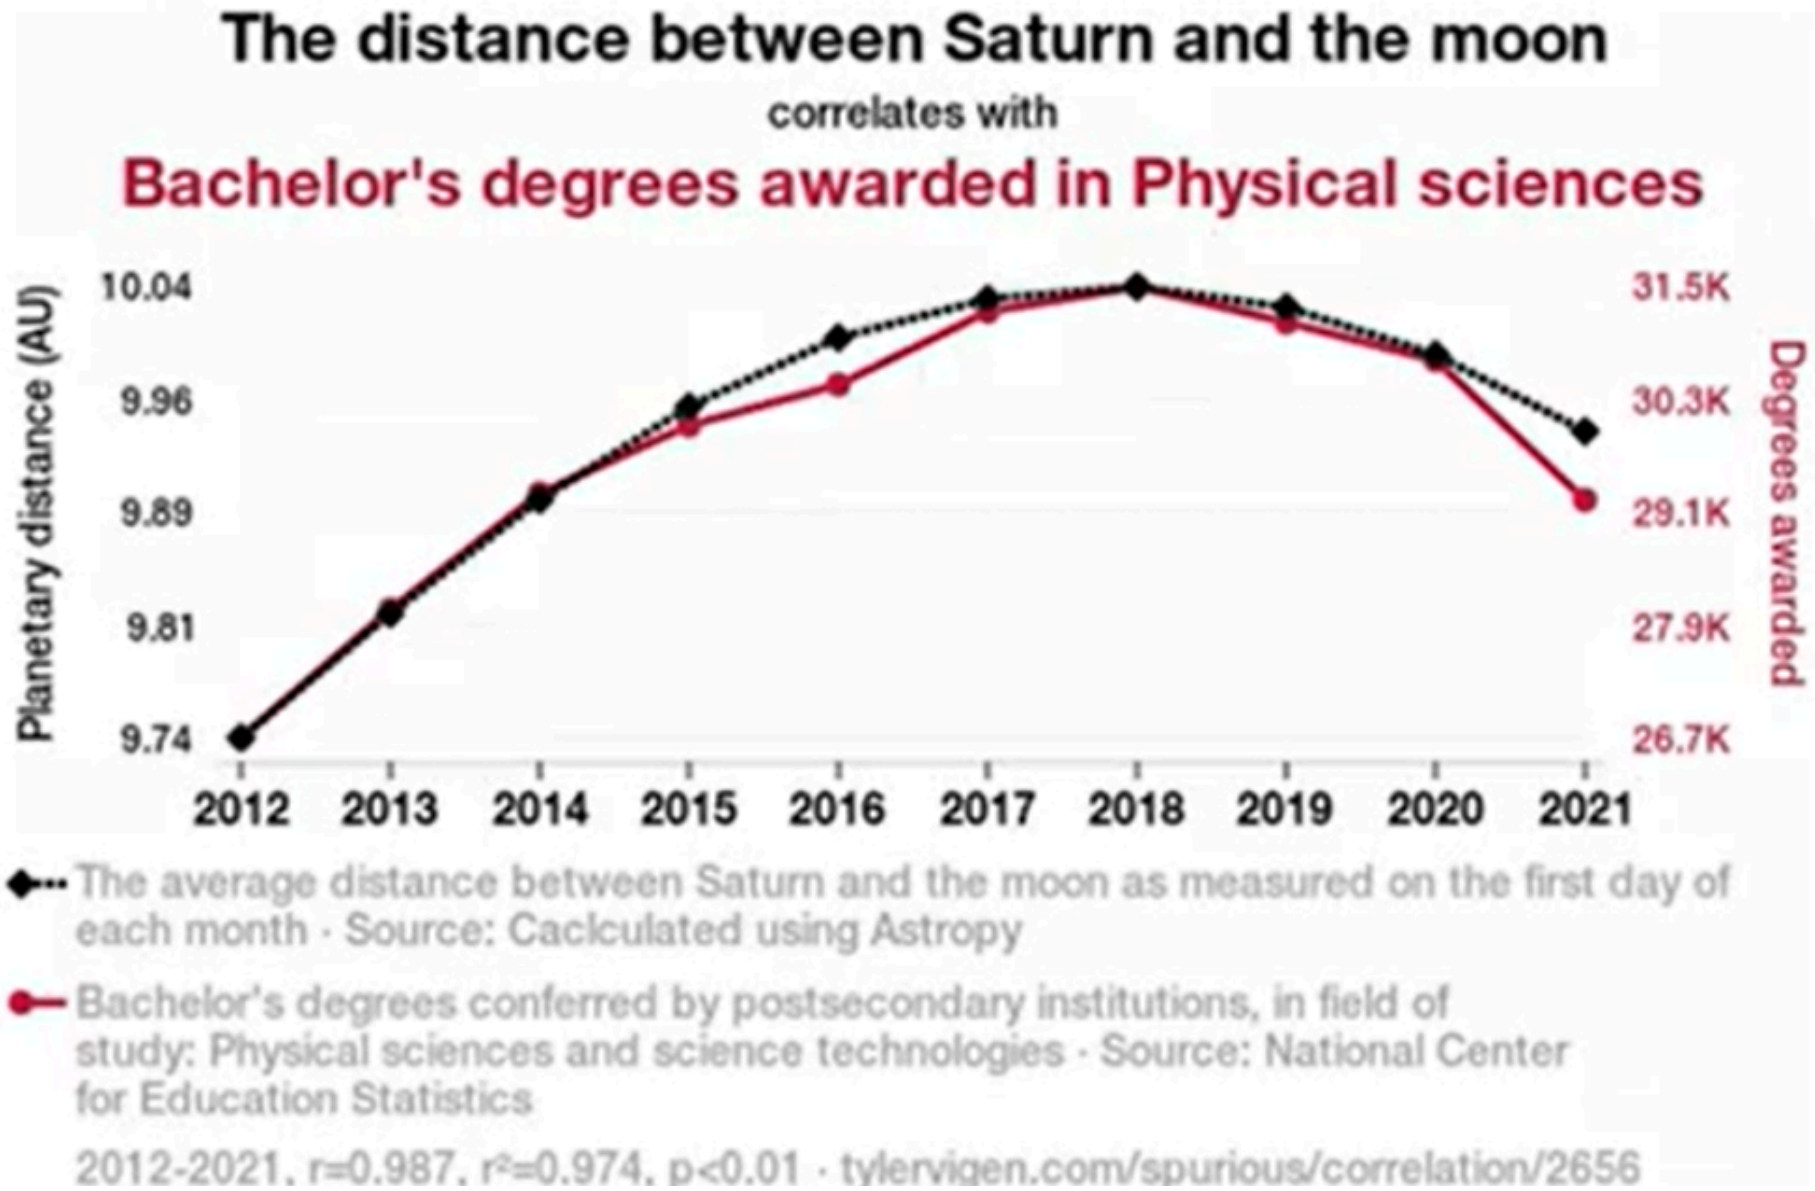
The distance between Saturn and the moon
correlates with
Bachelor's degrees awarded in Physical sciences
Planetary distance (AU)
10.04
9.96
9.89
9.81
9.74
31.5K
30.3K
29.1K
27.9K
26.7K
Degrees awarded
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
The average distance between Saturn and the moon as measured on the first day of each month · Source: Caclculated using Astropy
Bachelor's degrees conferred by postsecondary institutions, in field of study: Physical sciences and science technologies · Source: National Center for Education Statistics
2012-2021, r=0.987, r²=0.974, p<0.01 · tylervigen.com/spurious/correlation/2656

인과관계를 확인하기 위해서 가설을 세우자

- `비료의 양을 20% 늘리면 수확량이 15% 증가할 것이다` 라는 가설을 세우자.

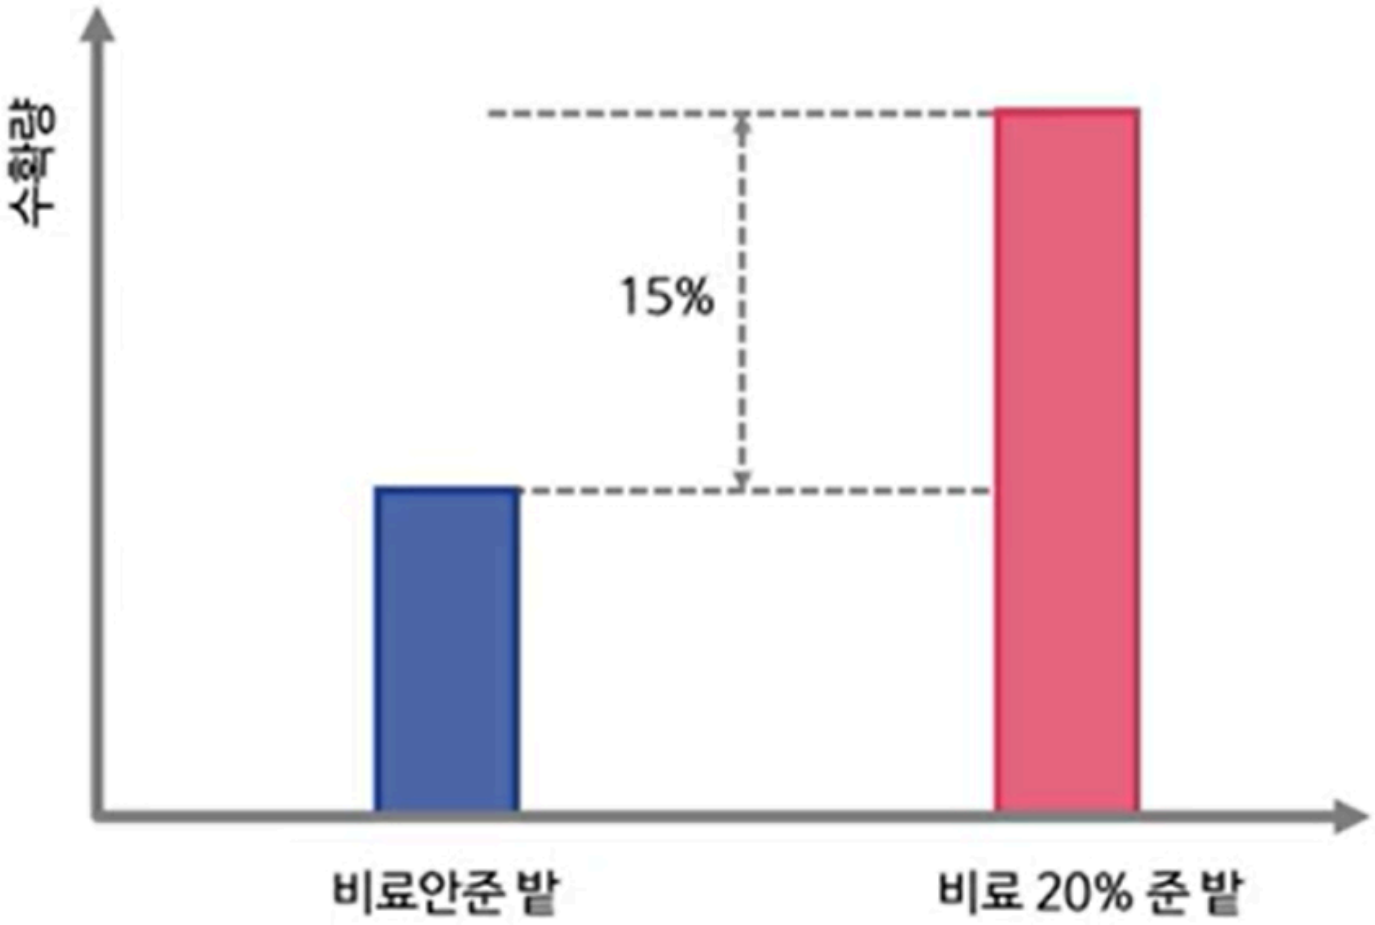

- 가설검정을 위해 실험을 진행했지만, 결과가 항상 일관되지는 않았습니다.
- 즉 어떤 때는 가설과 일치했고, 어떤 때는 그렇지 않았습니다.

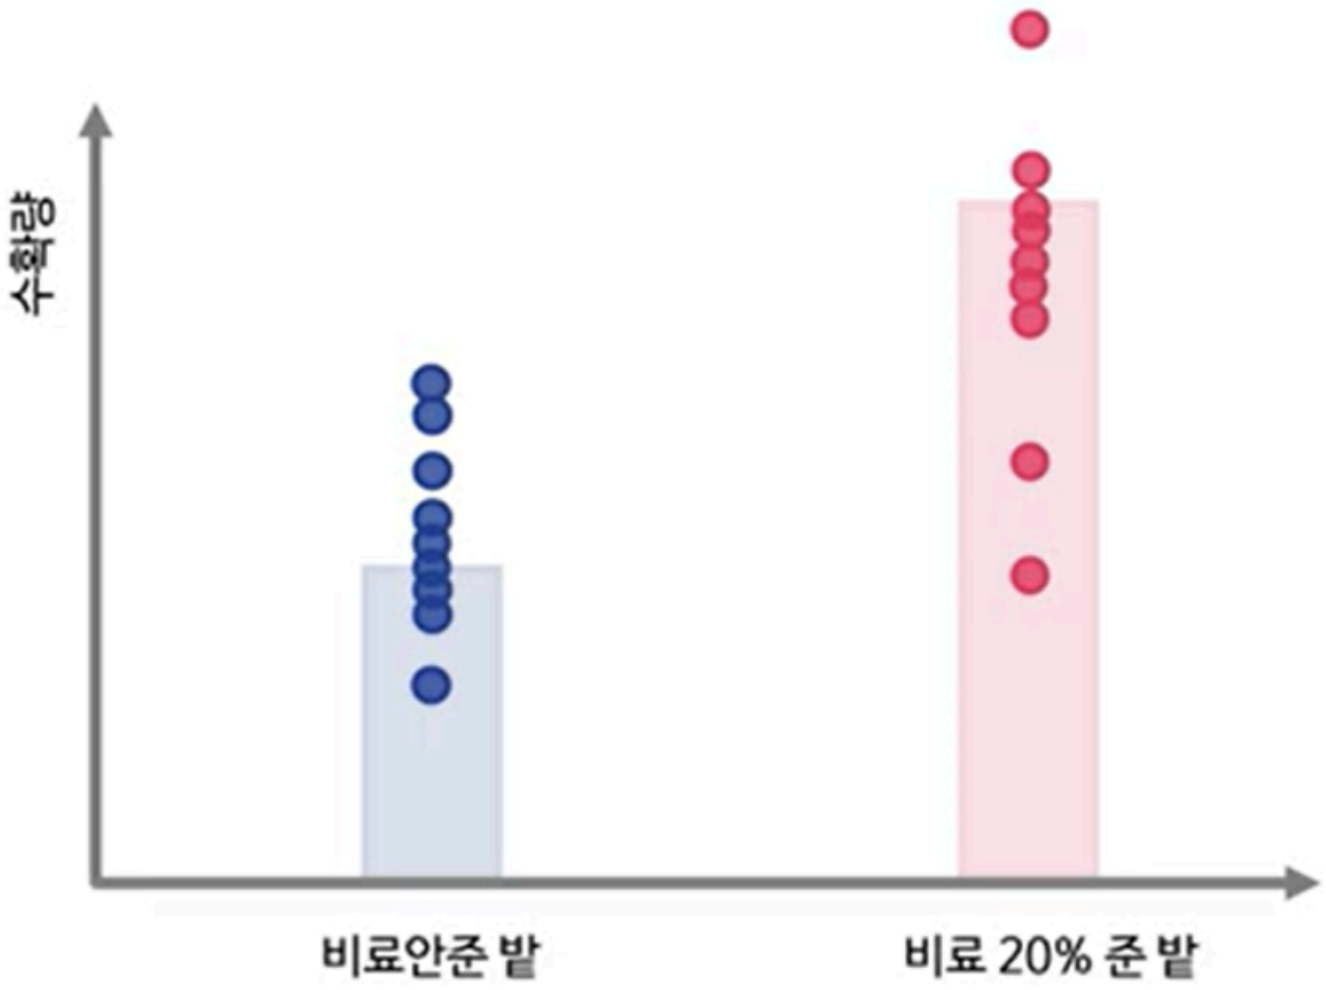

p-값

- 이런 불확실성을 줄이기 위해서 p-값이 필요합니다.
- p-값은 우리의 가설이 틀력다고 가정할 때, 관찰된 결과(또는 그보다 더 극단적인 결과)가 우연히 발생할 확률을 나타냅니다.

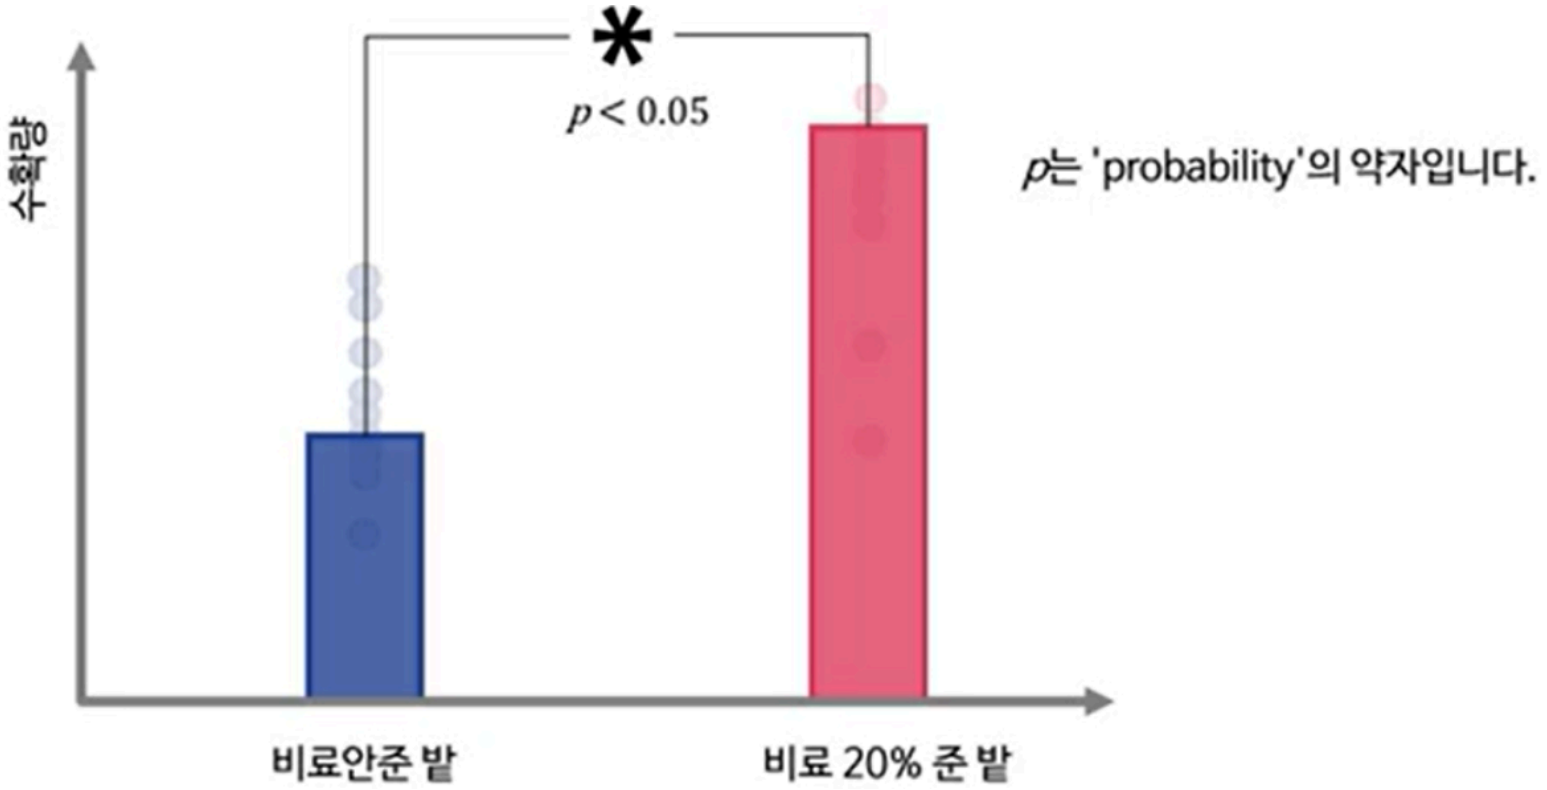

p-값이 너무 작을 경우, 통상 0.05보다 작을 경우, 귀무가설을 기각합니다.

귀무가설

Null hypothesis

H_o

비료는 수확량에 영향을 주지 않는다

$$p < 0.05$$

- 만약 95% 이상 확률로 비료가 수확량 증가에 영향을 준다면, 귀무가설을 기각하게 된다.
- 즉 비료의 양과 수확량은 서로 인과관계라고 할 수 있게 된다.

귀무가설	대립(실험)가설
Null hypothesis	Alternative Hypothesis
H_o	H_a
비료는 수확량에 영향을 주지 않는다	비료는 수확량에 영향을 준다.